Universidad del Valle de Guatemala

Facultad de Ingenieria - Departamento de Ciencias de la Computacion

Segundo semestre 2026

Laboratorio 11 - MLOps aplicado al Observatorio de Inteligencia Turistica

Avance: alcance, diagrama, pipeline inicial y controles de calidad

Integrantes

Javier Lopez - 23415

Pedro Avila - 23089

Brandon Rivera - 23088

Guatemala, 29 de octubre de 2026

1. Objetivo y alcance del flujo

El proposito de este laboratorio es dar al Observatorio de Inteligencia Turistica la capacidad de actualizar sus estimaciones de forma controlada y reproducible, de modo que siempre sea posible identificar que datos, codigo y configuracion produjeron el resultado que consulta un directivo. El avance define el alcance del flujo, su diagrama, un pipeline inicial ejecutable con un solo comando y los seis controles de calidad que deciden si una version puede publicarse.

Se reutiliza el repositorio y el tablero del Laboratorio 10, asi como la serie mensual de la Base de Migracion 2009-2026 trabajada en laboratorios anteriores. No se incorporan algoritmos nuevos; el procedimiento de estimacion del avance es un baseline estacional reproducible, suficiente para ejercitar todo el flujo de MLOps.

1.1 Variable que se estima

Atributo	Detalle
Variable	Movimientos mensuales de viajeros (flujo de entrada)
Unidad de medida	Personas (conteo de movimientos)
Nivel de agregacion	Mensual, nacional
Restricciones	Valor entero y no negativo
Destino asignado	flujo_mensual_nacional

1.2 Fuentes y columnas utilizadas

Fuente: Base de Migracion 2009-2026 (INGUAT / IGM), en su version MENSUAL. Los datos institucionales no se versionan ni se incluyen en las imagenes Docker; se leen por una ruta configurable. Columnas minimas indispensables:

Columna	Tipo	Descripcion
periodo	date	Primer dia del mes (YYYY-MM-01)
destino	texto	Serie o segmento estimado
viajeros	entero	Conteo de movimientos (numerador)
dias_fuente	entero	Dias reportados del mes (cobertura / denominador)
origen_fuente	texto	mensual | diaria_agregada (regla metodologica)

Clave de unicidad y granularidad: (periodo, destino). Un unico registro por mes y destino.

1.3 Periodos de ajuste y evaluacion

Concepto	Valor
Serie	2009-01 a 2025-12
Ajuste (entrenamiento)	2009-01 a 2021-03
Evaluacion (backtesting)	2021-04 a 2025-12
Meses ocultados en el avance	2025-11 y 2025-12

Enero / febrero 2026	No se calculan errores: no hay observados comparables (la clasificacion de la base cambio en 2023)

1.4 Parametros y supuestos (incluido el factor de reparto)

Parametro	Valor	Nota
metodo	baseline_estacional	Procedimiento reproducible del avance
ventana_nivel_meses	12	Meses recientes para estimar el nivel
semilla	42	Fija cualquier componente aleatorio
factor_reparto	perfil_estacional	Supuesto: los registros sin mes se reparten segun el indice estacional del destino; nunca sobre periodos sin cobertura
referencias	ultimo_valor, promedio_historico	Procedimientos simples de comparacion

El factor de reparto es un supuesto documentado y auditable: solo distribuye conteos agregados que carezcan de mes, y lo hace proporcionalmente al perfil estacional. Los periodos sin cobertura no se transforman en cero.

1.5 Archivo de resultados que utiliza el tablero

El tablero lee unicamente la version aprobada en results/approved/estimaciones.csv. Cada fila incluye:

Campo	Descripcion
destino	Serie estimada
periodo_estimado	Mes del valor
valor / unidad	Valor y unidad de medida
tipo	observado | estimacion
run_id	Identificador de la ejecucion
fecha_generacion	Fecha de generacion
version_procedimiento	Version del procedimiento
metrica_validacion_MAE	Metrica de validacion asociada

2. Diagrama del flujo

El flujo va desde la lectura de las fuentes hasta la consulta de las estimaciones por el directivo. Se marcan tres puntos criticos: donde se validan los datos (control de calidad), donde se evalua el procedimiento (regla de aceptacion) y donde se autoriza la publicacion (reemplazo de la version vigente).

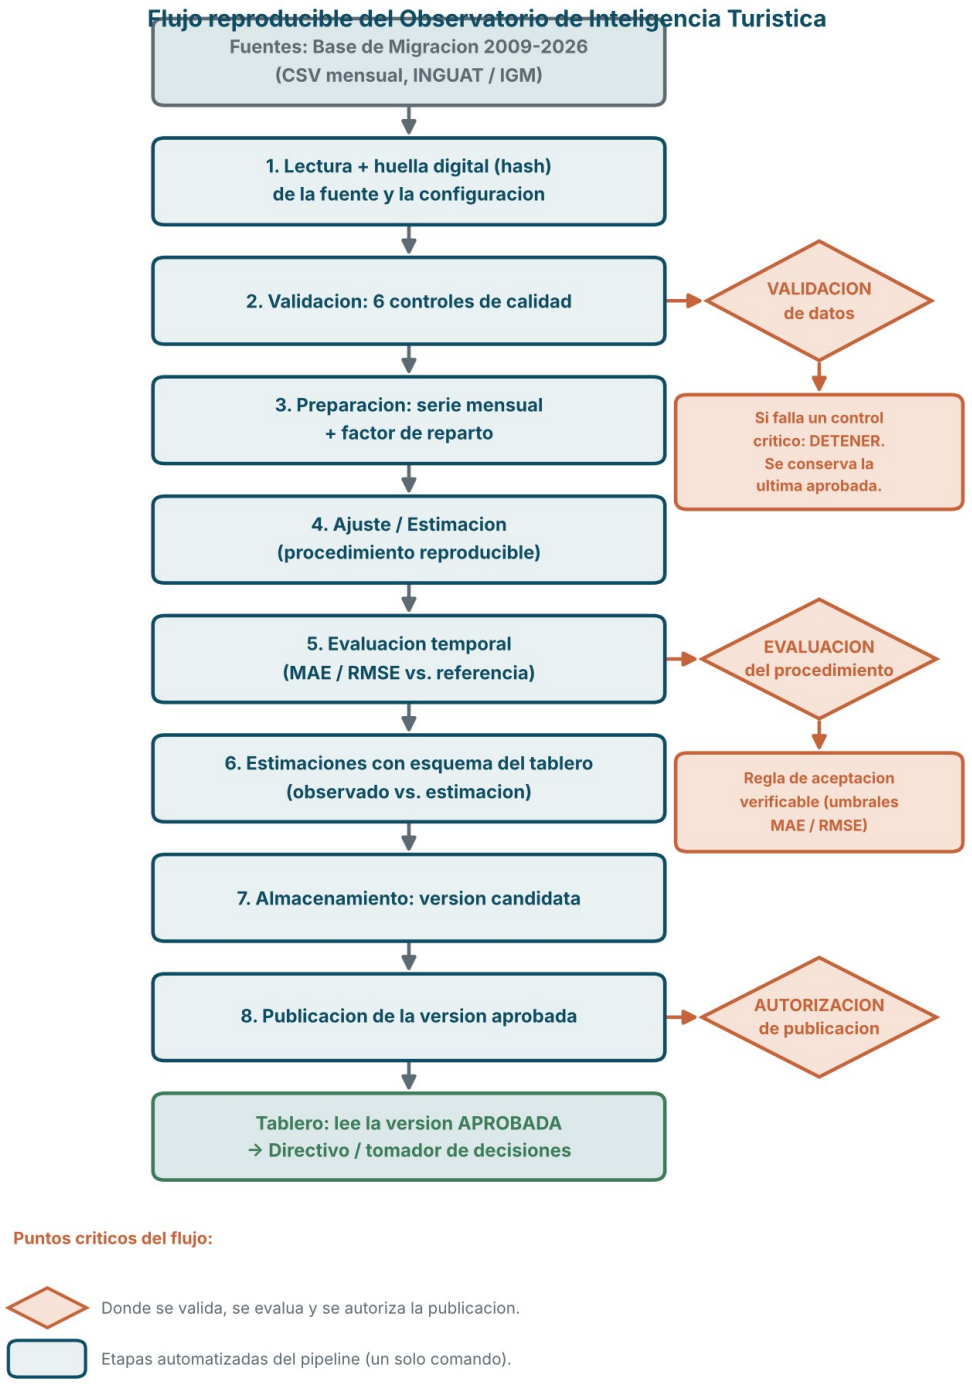


Figura 1. Flujo reproducible: ocho etapas automatizadas y los tres puntos de control, evaluacion y autorizacion.

El procesamiento esta separado de la interfaz: cambiar un filtro en el tablero no vuelve a ajustar el modelo, porque el tablero solo lee el archivo de la version aprobada.

3. Pipeline reproducible y configuracion

El pipeline automatiza las etapas de lectura, validacion, preparacion, estimacion, evaluacion, generacion de estimaciones, almacenamiento y publicacion. Se ejecuta con un solo comando documentado, sin modificar archivos intermedios a mano ni depender de la memoria de una sesion:

```
python -m src.run_pipeline --config config/config.yaml
```

Toda ruta, periodo, parametro y umbral vive en config/config.yaml; el codigo no contiene valores fijos. Las dependencias estan fijadas en requirements.txt (pandas 2.2.2, numpy 1.26.4, PyYAML 6.0.2) y se establece una semilla (42) para cualquier componente aleatorio. Cada corrida registra la huella digital (hash SHA-256) de la fuente y el identificador del commit de Git, para poder reproducir exactamente el resultado.

Etapa	Responsabilidad
1. Lectura	Carga la fuente configurada y calcula su huella digital
2. Validacion	Ejecuta los 6 controles; detiene si uno critico falla
3. Preparacion	Construye la serie mensual y aplica el factor de reparto
4. Estimacion	Calcula el procedimiento reproducible (orden temporal)
5. Evaluacion	MAE / RMSE del procedimiento frente a dos referencias
6. Estimaciones	Arma la tabla con el esquema del tablero
7. Almacenamiento	Guarda la version candidata y su reporte
8. Publicacion	Publica solo si la regla de aceptacion lo autoriza

4. Controles automaticos de calidad

Se implementan los seis controles minimos. Para cada uno se indica que verifica, cuando genera una advertencia (el flujo continua) y cuando detiene la ejecucion (control critico). Si falla un control critico, el pipeline se detiene antes de reemplazar los resultados vigentes del tablero, y los periodos sin cobertura nunca se convierten en cero.

#	Control	Que verifica	Advertencia	Detiene
1	Columnas y tipos	Existencia de variables indispensables y tipos compatibles	-	Falta una columna o el tipo es incompatible
2	Fechas y cobertura	Fechas validas y periodos requeridos	Periodo sin informacion o cobertura parcial (< 20 dias)	Fecha invalida
3	Unicidad	Duplicados segun (periodo, destino)	-	Existe cualquier duplicado
4	Valores faltantes	Ausencias	NA en columna de	NA en periodo,

		permitidas vs. bloqueantes	ausencia permitida	destino o viajeros
5	Valores y denominadores	Conteos negativos, no finitos, denominador 0	-	Negativos, inf/NaN o dias_fuente = 0
6	Regla metodologica	La serie mensual proviene de la fuente mensual	-	Algun mes proviene de 'diaria_agregada'

Cada corrida genera un reporte de calidad (results/candidate/reporte_calidad.json) con el estado de los seis controles y la decision de detener o continuar.

5. Evidencia de ejecucion

5.1 Corrida valida

Con datos integros, los seis controles pasan y el procedimiento supera a las dos referencias sobre los meses ocultados:

Procedimiento	MAE (personas/mes)
baseline_estacional (propio)	10,414
Referencia: ultimo valor observado	65,872
Referencia: promedio historico	89,432

Resultado: version APROBADA y publicada en results/approved. La regla de aceptacion exige que ningun control critico falle, que la salida este completa y que el MAE y el RMSE no superen los umbrales definidos segun la escala de la variable.

5.2 Prueba de deteccion y recuperacion

Sobre una copia de los datos se introdujo una columna ausente. El pipeline detecto el problema en los controles 1 y 5, se detuvo (codigo de salida 2) y conservo intacta la ultima version aprobada del tablero. Tras corregir el dato, la ejecucion vuelve a aprobar y publicar. Esto demuestra que una falla critica no reemplaza los resultados disponibles.

6. Proximos pasos hacia el trabajo final (1 de noviembre)

- Registro de cada ejecucion en MLflow Tracking (codigo, fuentes, parametros, metricas, controles y artefactos), con al menos dos corridas equivalentes.
- Regla de aceptacion formal sobre varios meses de backtesting y comparacion sistematica con las referencias.
- Integracion con el tablero: distinguir observado de estimacion, mostrar fecha de actualizacion, metrica y advertencia de limitaciones.

- Monitoreo (actualizacion, calidad y resultados) y restauracion documentada de una version anterior.
- Contenerizacion con Docker / Docker Compose, con persistencia de MLflow y de las versiones aprobadas, reproducible desde una copia limpia del repositorio.

Referencias

MLflow. (2026). MLflow Tracking. https://mlflow.org/docs/latest/ml/tracking

Docker. (2026). Docker Compose. https://docs.docker.com/compose/

INGUAT / IGM. Base de Migracion 2009 - junio 2026 (datos compartidos con fines academicos).